

# **Tratado Avançado sobre Processamento Digital de Imagens: Fundamentos Teóricos, Análise de Textura e Algoritmos de Extração de Características**

## **1. Introdução à Quantificação da Informação Visual**

A análise computacional de imagens transcendeu a mera reprodução visual para se estabelecer como uma disciplina analítica rigorosa, capaz de extrair descritores quantitativos de matrizes de dados não estruturados. A transição de uma imagem digital — essencialmente uma matriz bidimensional de intensidades discretas — para informações de alto nível, como o diagnóstico de patologias cerebrais ou a detecção de falhas em malhas têxteis, exige uma compreensão profunda da estatística espacial, da geometria computacional e da teoria da informação.<sup>1</sup>

Este relatório dissecava a arquitetura teórica e algorítmica de um sistema robusto de visão computacional. O foco reside na integração de múltiplas modalidades de análise: a decomposição espectral através de espaços de cor (HSV), a manipulação estocástica de histogramas para realce de contraste, a modelagem estatística de segunda ordem via Matrizes de Co-ocorrência de Níveis de Cinza (GLCM) proposta por Haralick, a quantificação de incerteza via Entropia de Shannon e a análise estrutural através de operadores de gradiente (Sobel) e aproximação poligonal (Douglas-Peucker). A análise demonstra como a convergência desses métodos permite a detecção de anomalias baseadas tanto em aberrações cromáticas quanto em rupturas de padrões texturais, fundamentais em aplicações críticas onde a inspeção humana é falível ou subjetiva.<sup>3</sup>

## **2. Espaços de Cor e Decomposição Espectral: Do RGB**

# ao HSV

## 2.1 Limitações do Modelo Aditivo RGB

A representação padrão de imagens digitais baseia-se no modelo RGB (*Red, Green, Blue*), um sistema de coordenadas cartesianas que mimetiza a tricromacia da visão humana. Contudo, para fins de análise computacional, o RGB apresenta uma correlação intrínseca problemática: a cromaticidade (informação de cor) e a luminância (intensidade de luz) estão entrelaçadas em todos os três canais. Uma variação na iluminação de uma cena altera simultaneamente os valores de R, G e B, o que complica a segmentação de objetos baseada puramente na cor.<sup>5</sup>

## 2.2 O Modelo Cilíndrico HSV e a Percepção Computacional

Para mitigar a sensibilidade à iluminação, a literatura e as práticas de engenharia convergem para o uso do espaço de cor HSV (*Hue, Saturation, Value*). Geometricamente, o HSV reorganiza o cubo RGB em um cilindro ou cone, onde as coordenadas possuem significados perceptuais distintos:

- **Matiz (Hue - H):** Representa a frequência dominante da cor, mapeada angularmente de 0° a 360°. Esta dimensão é invariante a mudanças de brilho, permitindo, por exemplo, que um objeto vermelho seja identificado consistentemente tanto na sombra quanto sob luz direta.<sup>5</sup>
- **Saturação (Saturation - S):** Define a pureza da cor ou a distância radial a partir do eixo central de cinzas. Cores com baixa saturação aproximam-se de tons de cinza, enquanto alta saturação indica vivacidade espectral.<sup>8</sup>
- **Valor (Value - V):** Corresponde à intensidade luminosa ou brilho, variando ao longo do eixo vertical do cilindro.

A utilidade algorítmica do HSV é evidente em tarefas de segmentação. Ao isolar o canal H, algoritmos podem estabelecer limiares (thresholds) que separam objetos de interesse do fundo com robustez superior à do espaço RGB, especialmente em ambientes com iluminação não controlada.<sup>6</sup>

## 3. Pré-processamento e Realce de Sinal: Equalização de Histograma

Antes da extração de características complexas, a normalização radiométrica da imagem é imperativa. A técnica de **Equalização de Histograma** opera sob o princípio da maximização da entropia global da imagem, redistribuindo as intensidades dos pixels para cobrir toda a faixa dinâmica disponível (geralmente 0-255 em imagens de 8 bits).<sup>10</sup>

### 3.1 Fundamentação Estatística

Considere uma imagem digital como uma função discreta de intensidades  $r$  no intervalo  $[0, L-1]$ . A probabilidade de ocorrência de um nível de intensidade  $r_k$  é dada por:

$$p_r(r_k) = \frac{n_k}{MN}$$

Onde  $n_k$  é o número de pixels com intensidade  $r_k$ , e  $MN$  é o número total de pixels na imagem. A equalização busca uma transformação  $s_k = T(r_k)$  tal que o histograma de saída seja uniforme. Matematicamente, esta transformação é a Função de Distribuição Acumulada (CDF) normalizada da imagem original:

$$s_k = (L-1) \sum_{j=0}^k p_r(r_j)$$

Esta operação não linear expande o contraste local, revelando detalhes sutis em regiões que estariam ocultas em histogramas concentrados (imagens muito escuras ou muito claras).<sup>11</sup> A aplicação desta técnica é um pré-requisito vital para a detecção de bordas subsequente, pois gradientes de intensidade tornam-se mais pronunciados após a equalização, facilitando a convergência de operadores diferenciais.<sup>13</sup>

## 4. Teoria da Análise de Textura: Matrizes de Co-ocorrência (GLCM)

Enquanto o histograma analisa a distribuição global de intensidades (estatística de primeira ordem), ele falha em capturar a organização espacial dos pixels. Uma imagem de ruído aleatório e uma imagem de um padrão xadrez podem ter histogramas idênticos. Para distinguir tais casos, utiliza-se a **Matriz de Co-ocorrência de Níveis de Cinza (GLCM)**, uma

ferramenta estatística de segunda ordem introduzida por Haralick em 1973.<sup>1</sup>

## 4.1 Construção e Mecânica da GLCM

A GLCM é uma matriz quadrada  $P(i,j | d, \theta)$  de dimensão  $N_g \times N_g$ , onde  $N_g$  é o número de níveis de cinza. Cada elemento  $(i, j)$  representa a probabilidade conjunta de que dois pixels, separados por uma distância espacial  $d$  e um ângulo  $\theta$ , tenham intensidades  $i$  e  $j$ , respectivamente.<sup>14</sup>

A matriz não normalizada é definida como:

$$P_{d,\theta}(i,j) = \sum_{x=1}^M \sum_{y=1}^N \begin{cases} 1 & \text{se } I(x,y)=i \text{ e} \\ & I(x+\Delta x, y+\Delta y)=j \neq 0 \text{ e caso contrário} \\ 0 & \text{caso contrário} \end{cases}$$

Os parâmetros de deslocamento  $(\Delta x, \Delta y)$  são derivados de  $d$  e  $\theta$ . Por exemplo, um ângulo de  $0^\circ$  com  $d=1$  corresponde a  $(\Delta x=1, \Delta y=0)$ , analisando a vizinhança horizontal imediata à direita.<sup>16</sup> É crucial notar que, em implementações como a da biblioteca scikit-image, a orientação dos ângulos pode seguir o sentido horário, exigindo atenção rigorosa na definição dos vetores de direção.<sup>18</sup>

## 4.2 Descritores de Haralick: Fórmulas e Interpretação

A GLCM bruta é uma matriz densa de difícil interpretação direta. Haralick propôs 14 descritores escalares extraídos dessa matriz para resumir o conteúdo textural. Os mais significativos para classificação de imagens (como detecção de tumores ou defeitos em tecidos) são detalhados na tabela a seguir:

Descriptor	Formulação Matemática	Interpretação Física e Aplicação
<b>Contraste (Inércia)</b>	$\sum_{i,j} (i-j)^2 p(i,j)$	Pondera a probabilidade pelo quadrado da diferença de intensidade. Valores altos indicam transições abruptas (bordas fortes). Em

		tecidos, picos de contraste local sinalizam defeitos como furos ou nós. <sup>1</sup>
<b>Homogeneidade (IDM)</b>	$\sum_{i,j} \frac{p(i,j)}{1 + (i-j)^2}$	Inversamente proporcional ao contraste. O denominador penaliza diferenças de intensidade. É máxima quando a GLCM é diagonal, indicando uniformidade visual. Defeitos estruturais reduzem drasticamente a homogeneidade local. <sup>20</sup>
<b>Energia (ASM)</b>	$\sum_{i,j} p(i,j)^2$	Mede a ordem ou repetitividade. Se a textura é periódica e consistente, a GLCM tem poucas entradas com valores altos, resultando em alta energia (soma dos quadrados). Texturas caóticas distribuem a probabilidade, baixando a energia. <sup>1</sup>
<b>Correlação</b>	$\sum_{i,j} \frac{(i-\mu_i)(j-\mu_j)p(i,j)}{\sigma_i \sigma_j}$	Mede a dependência linear de níveis de cinza. Detecta estruturas direcionais. Em imagens médicas, ajuda a diferenciar tecidos com orientação fibrosa de massas tumorais amorfas. <sup>15</sup>
<b>Dissimilaridade</b>	$\sum_{i,j} i-j$	

Além destes, existem métricas avançadas como a **Variância (Soma dos Quadrados)**, que mede a heterogeneidade em torno da média, e as **Medidas de Informação de Correlação (IMC1, IMC2)**, que utilizam conceitos de entropia para quantificar dependências não lineares na textura.<sup>20</sup>

## 4.3 Distribuições Marginais e Diagonais

A teoria da GLCM estende-se ao cálculo de distribuições marginais. A soma das entradas da GLCM ao longo de diagonais paralelas à diagonal principal ( $k = |i-j|$ ) fornece a distribuição das diferenças de níveis de cinza  $p_{\{x-y\}}(k)$ . Similarmente, a soma ao longo das diagonais secundárias ( $k = i+j$ ) fornece  $p_{\{x+y\}}(k)$ .<sup>15</sup> Estas distribuições secundárias são fundamentais para calcular métricas complexas como a "Soma Média" e a "Diferença de Entropia", que oferecem nuances sutis sobre a granulosidade da imagem.

## 5. Teoria da Informação: Entropia de Shannon na Análise de Imagens

A Entropia, conforme definida por Claude Shannon em 1948, quantifica a incerteza ou o conteúdo de informação médio de uma fonte de dados.<sup>22</sup> No processamento de imagens, a entropia serve como uma medida robusta da complexidade textural e da desordem visual.

### 5.1 Entropia Global vs. Local

A entropia pode ser calculada em duas escalas distintas, com implicações diagnósticas diferentes:

1. Entropia Global (Baseada em Histograma): Calculada sobre a distribuição de probabilidade de intensidades de toda a imagem ou ROI (Região de Interesse):

$$H(X) = - \sum_{i=0}^{N_g-1} p(i) \log_2 p(i)$$

Imagens com textura rica ou ruído tendem a ter histogramas planos e, consequentemente, alta entropia. Imagens com grandes áreas de cor sólida têm baixa entropia. Em diagnósticos médicos, a degradação da imagem ou a perda de detalhes texturais pode ser monitorada através da queda nos valores de entropia global.<sup>23</sup>

2. Entropia Local (Baseada em Elemento Estruturante):

Para segmentação, utiliza-se a entropia local, calculada dentro de uma janela deslizante (geralmente um disco ou quadrado de raio  $r$ ) centrada em cada pixel.

$$\$ \$ E_{\{local\}}(x,y) = H(\text{vizinhança}_r(x,y)) \$ \$$$

Esta operação transforma a imagem original em um mapa de entropia. Regiões de alta textura (como um tumor vascularizado) aparecem com alta intensidade no mapa de entropia, enquanto regiões lisas (como fluido cerebroespinhal ou fundo homogêneo) aparecem escuras. O filtro skimage.filters.rank.entropy implementa essa lógica, sendo uma ferramenta poderosa para detecção de bordas de textura que não possuem gradientes de intensidade fortes, mas sim mudanças na estatística local.<sup>25</sup>

## 6. Análise Estrutural e Detecção de Bordas: O Operador Sobel

Enquanto a GLCM e a Entropia analisam a textura interna das regiões, a definição precisa das fronteiras físicas dos objetos requer operadores de diferenciação espacial. O **Operador Sobel** é o padrão industrial para esta tarefa, atuando como uma aproximação discreta do gradiente da função de intensidade da imagem.<sup>28</sup>

### 6.1 Convolução e Estimativa de Gradiente

O operador Sobel utiliza dois kernels de convolução  $3 \times 3$ ,  $G_x$  e  $G_y$ , desenhados para detectar variações de intensidade nas direções horizontal e vertical, respectivamente. A estrutura dos kernels incorpora um fator de suavização (pesos gaussianos na linha/coluna central) para reduzir a sensibilidade ao ruído de alta frequência, comum em derivadas puras.<sup>29</sup>

$$\$ \$ G_x = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix} \quad , \quad G_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ +1 & +2 & +1 \end{bmatrix} \$ \$$$

A convolução desses kernels com a imagem original  $A$  resulta em dois mapas de derivadas parciais:  $G_x = G_x * A$  e  $G_y = G_y * A$ .

### 6.2 Magnitude e Orientação do Vetor Gradiente

Para cada pixel, o vetor gradiente  $\nabla A$  aponta na direção da maior taxa de variação de intensidade. A magnitude deste gradiente, que corresponde à força da borda, é dada pela norma Euclidiana:

$$G = \sqrt{G_x^2 + G_y^2}$$

Em implementações otimizadas para hardware embarcado ou tempo real, utiliza-se frequentemente a aproximação da norma L1 ( $G \approx |G_x| + |G_y|$ ), que é computacionalmente mais barata, embora introduza erros de anisotropia.<sup>31</sup> A direção da borda ( $\Theta$ ) também pode ser calculada como  $\Theta = \arctan(G_y / G_x)$ , sendo útil para rastreamento de contornos direcionais. O resultado final do filtro Sobel é uma imagem onde pixels de borda possuem valores de intensidade elevados, destacando a estrutura esquelética dos objetos presentes na cena.<sup>33</sup>

## 7. Geometria Computacional e Simplificação de Formas

Após a detecção de bordas, a imagem é frequentemente convertida em um conjunto de contornos vetoriais. No entanto, contornos extraídos de imagens reais são ruidosos e contêm um excesso de vértices redundantes. Para análise de forma (Shape Analysis), é necessário simplificar esses polígonos sem perder sua topologia essencial.

### 7.1 O Algoritmo Ramer-Douglas-Peucker (RDP)

O algoritmo Ramer-Douglas-Peucker é a técnica fundamental para a aproximação de curvas poligonais. Ele opera sob uma lógica recursiva de "dividir e conquistar" para reduzir o número de pontos de uma curva, mantendo o desvio máximo dentro de um limiar  $\epsilon$  (epsilon) especificado.<sup>34</sup>

#### Mecanismo de Funcionamento:

1. Seleciona-se o primeiro e o último ponto da curva original e traça-se uma linha reta (corda) entre eles.
2. Calcula-se a distância perpendicular de todos os pontos intermediários até essa reta.
3. Identifica-se o ponto com a maior distância  $d_{max}$ .
4. **Decisão de Limiar:**
  - o Se  $d_{max} < \epsilon$ : A variação é considerada ruído desprezível. Todos os

- pontos intermediários são descartados, e a curva é aproximada pela reta inicial.
- Se  $d_{\max} \geq \epsilon$ : O ponto é retido como um vértice significativo (uma "quina"). A curva é dividida nesse ponto, e o algoritmo é aplicado recursivamente às duas subseções resultantes.

A escolha de  $\epsilon$  é crítica: valores baixos preservam detalhes finos (ideal para texturas rugosas), enquanto valores altos abstraem a forma para polígonos primitivos (útil para classificar objetos como "retangulares" ou "circulares").<sup>36</sup>

## 8. Aplicações Específicas: Detecção de Tumores e Inspeção Têxtil

A teoria apresentada materializa-se em aplicações práticas distintas, conforme evidenciado na literatura de referência.

### 8.1 Análise de Simetria em Imagens Médicas (Tumores Cerebrais)

Em neuroimagem, a detecção de tumores frequentemente explora a simetria bilateral natural do cérebro humano. Tumores introduzem desvios de massa e textura que quebram essa simetria. Algoritmos avançados extraem o Plano Médio Sagital (MSP) e calculam um **Índice de Assimetria (AI)**:

$$AI = \frac{A_{\text{esquerda}} - A_{\text{direita}}}{A_{\text{total}}} \times 100\%$$

Além da área, compara-se a divergência estatística entre os histogramas e as características GLCM dos hemisférios esquerdo e direito. Um desvio significativo na "Homogeneidade" ou "Entropia" entre regiões homólogas é um biomarcador forte de patologia.<sup>2</sup>

### 8.2 Detecção de Defeitos em Tecidos

Na indústria têxtil, a inspeção visual automática baseia-se na quebra de periodicidade. Tecidos normais possuem alta energia e correlação regular na GLCM. Defeitos como "fio quebrado" (broken end), "barra fina" (thin bar) ou nós (knots) manifestam-se como picos

locais de Contraste e quedas abruptas de Homogeneidade e Energia. A análise comparativa entre a GLCM de um gabarito "perfeito" e a amostra inspecionada permite a classificação do defeito com precisão superior a filtros de frequência (como Gabor) em certos contextos de tecelagem.<sup>3</sup>

---

## 9. Passo a Passo Explicativo do Funcionamento do Código

Esta seção dissecava o fluxo lógico de um script computacional hipotético, mas representativo do estado da arte, que implementa as teorias supracitadas. O objetivo é elucidar o "como" e o "porquê" de cada função no pipeline de processamento.

### Fase 1: Inicialização e Carregamento de Dados

O processo inicia-se com a importação de bibliotecas essenciais: cv2 (OpenCV) para manipulação de imagem, numpy para operações vetoriais e skimage (Scikit-Image) para algoritmos avançados de textura.

- **Ação:** A imagem é carregada do disco para a memória RAM.
- **Verificação:** O código inspeciona a profundidade de bits (ex: uint8) e as dimensões da matriz.

### Fase 2: Pré-processamento e Conversão Espectral

A imagem bruta RGB raramente é adequada para análise direta devido ao ruído e correlação de canais.

1. **Conversão para Escala de Cinza (cv2.cvtColor):**
  - **Lógica:** Aplica a equação de luminância  $Y = 0.299R + 0.587G + 0.114B$ .
  - **Propósito:** Reduz a complexidade tridimensional para uma matriz 2D, pré-requisito para GLCM e Sobel.
2. **Conversão para HSV:**
  - **Lógica:** Transforma coordenadas cartesianas em cilíndricas.

- **Propósito:** Permite a criação de máscaras de segmentação baseadas puramente na cor (Matiz), ignorando sombras.
3. **Filtragem Gaussiana (cv2.GaussianBlur):**
    - **Lógica:** Convolui a imagem com um kernel gaussiano  $5 \times 5$ .
    - **Propósito:** Remove ruído "sal e pimenta" que poderia causar falsos positivos na detecção de bordas Sobel.<sup>29</sup>
  4. **Equalização de Histograma (cv2.equalizeHist):**
    - **Lógica:** Calcula a CDF e remapeia as intensidades.
    - **Propósito:** Expande o contraste local, garantindo que texturas em áreas escuras sejam visíveis para a GLCM.<sup>10</sup>

## **Fase 3: Extração de Características de Textura (Motor GLCM)**

Esta é a etapa computacionalmente intensiva onde a quantificação ocorre.

1. **Configuração da GLCM (graycomatrix):**
  - **Parâmetros:** Define-se distâncias (ex: '') e ângulos (ex: [0, np.pi/4, np.pi/2]).
  - **Nuance de Implementação:** Em skimage, o ângulo 0 radianos aponta para a direita (leste), e a função retorna uma matriz 4D (n\_níveis, n\_níveis, n\_distâncias, n\_ângulos). O código deve tratar corretamente esses índices para evitar leituras errôneas de direção.<sup>16</sup>
2. **Cálculo de Propriedades (graycoprops):**
  - **Execução:** A função itera sobre a GLCM calculada, aplicando as fórmulas de Haralick (Contraste, Dissimilaridade, Homogeneidade, Energia, Correlação).
  - **Saída:** Vetores de características que descrevem a textura. Por exemplo, um valor alto de "Contraste" em uma região de tecido liso aciona um alerta de defeito.<sup>41</sup>

## **Fase 4: Análise de Entropia e Segmentação**

1. **Cálculo da Entropia de Shannon (shannon\_entropy):**
  - Gera um valor escalar global indicando a complexidade geral da imagem.<sup>43</sup>
2. **Mapeamento de Entropia Local (rank.entropy):**
  - Passa-se um elemento estruturante (ex: disco de raio 5).
  - O algoritmo calcula a entropia para cada vizinhança, gerando uma nova imagem onde o brilho do pixel corresponde à desordem local. Isso destaca regiões tumorais ou texturas complexas que o olho humano pode perder.<sup>25</sup>

## Fase 5: Definição Estrutural (Sobel e Contornos)

1. **Gradiente Sobel (cv2.Sobel):**
  - o Calcula-se as derivadas  $dx$  e  $dy$  separadamente usando dados de ponto flutuante (CV\_64F) para preservar sinais negativos.
  - o Combina-se os resultados na magnitude do gradiente.
2. **Binarização e Contornos (cv2.findContours):**
  - o Aplica-se um limiar na imagem de magnitude Sobel.
  - o O algoritmo de rastreamento de bordas converte o mapa de bits em vetores de pontos.
3. **Simplificação Geométrica (cv2.approxPolyDP):**
  - o Aplica-se o algoritmo Ramer-Douglas-Peucker com um  $\epsilon$  calculado dinamicamente (ex: 1% do perímetro do contorno).
  - o Isso reduz contornos orgânicos de tumores ou defeitos a formas poligonais tratáveis, permitindo a medição rápida de área e perímetro para cálculo de índices de assimetria.<sup>37</sup>

## 10. Análise Crítica dos Métodos

A arquitetura descrita representa uma abordagem clássica e determinística ("Hand-crafted features"). A vantagem deste método sobre redes neurais profundas (Deep Learning) reside na **explicabilidade**. Cada número gerado — seja a Homogeneidade de Haralick ou a Magnitude Sobel — possui um significado físico direto, permitindo que médicos e engenheiros validem o "raciocínio" do algoritmo. Contudo, a dependência de parâmetros manuais (tamanho de janela, limiares, ângulos GLCM) exige calibração cuidadosa para cada domínio de aplicação. A integração de todas essas técnicas — cor, textura, entropia e forma — cria um sistema resiliente, onde a fraqueza de um descritor é compensada pela robustez de outro, culminando em diagnósticos visuais de alta precisão.

### Referências citadas

1. HaralickTextureExtraction — Orfeo ToolBox 9.1.0 documentation, acessado em novembro 18, 2025,  
[https://www.orfeo-toolbox.org/CookBook/Applications/app\\_HaralickTextureExtraction.html](https://www.orfeo-toolbox.org/CookBook/Applications/app_HaralickTextureExtraction.html)
2. A Symmetrical Approach to Brain Tumor Segmentation in MRI Using Deep

- Learning and Threefold Attention Mechanism - MDPI, acessado em novembro 18, 2025, <https://www.mdpi.com/2073-8994/15/10/1912>
- 3. (PDF) "FABRIC IMAGE DEFECT DETECTION BY USING GLCM AND ROSETTA", acessado em novembro 18, 2025, [https://www.researchgate.net/publication/321419099\\_FABRIC\\_IMAGE\\_DEFECT\\_DETECTION\\_BY\\_USING\\_GLCM\\_AND\\_ROSETTA](https://www.researchgate.net/publication/321419099_FABRIC_IMAGE_DEFECT_DETECTION_BY_USING_GLCM_AND_ROSETTA)
  - 4. Visual-Based Defect Detection and Classification Approaches for Industrial Applications—A SURVEY - PubMed Central, acessado em novembro 18, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC7085592/>
  - 5. HSL and HSV - Wikipedia, acessado em novembro 18, 2025, [https://en.wikipedia.org/wiki/HSL\\_and\\_HSV](https://en.wikipedia.org/wiki/HSL_and_HSV)
  - 6. How to find HSV range of an Object for Computer Vision applications? - Medium, acessado em novembro 18, 2025, <https://medium.com/programming-fever/how-to-find-hsv-range-of-an-object-for-computer-vision-applications-254a8eb039fc>
  - 7. OpenCV Color Spaces and Conversion: An Introduction - Roboflow Blog, acessado em novembro 18, 2025, <https://blog.roboflow.com/opencv-color-spaces/>
  - 8. acessado em novembro 18, 2025, [https://blog.roboflow.com/opencv-color-spaces/#:~:text=The%20HSV%20Color%20Space,brightness%20\(value\)%20and%20saturation.](https://blog.roboflow.com/opencv-color-spaces/#:~:text=The%20HSV%20Color%20Space,brightness%20(value)%20and%20saturation.)
  - 9. Interactive Color Image Segmentation using HSV Color Space, acessado em novembro 18, 2025, <https://mzu.edu.in/wp-content/uploads/2020/05/Interactive-Color-Image-Segmentation-using-HSV-Color-Space.pdf>
  - 10. Histogram equalization | Images as Data Class Notes - Fiveable, acessado em novembro 18, 2025, <https://fiveable.me/images-as-data/unit-3/histogram-equalization/study-guide/iQf8HnpPT50oFvWf>
  - 11. Histogram equalization - Wikipedia, acessado em novembro 18, 2025, [https://en.wikipedia.org/wiki/Histogram\\_equalization](https://en.wikipedia.org/wiki/Histogram_equalization)
  - 12. Histogram Equalization in Digital Image Processing - GeeksforGeeks, acessado em novembro 18, 2025, <https://www.geeksforgeeks.org/computer-graphics/histogram-equalization-in-digital-image-processing/>
  - 13. Back-to-basics Part 1: Histogram Equalization in Image Processing | by Animesh Karnewar, acessado em novembro 18, 2025, <https://medium.com/@animeshsk3/back-to-basics-part-1-histogram-equalization-in-image-processing-f607f33c5d55>
  - 14. Textural Features for Image Classification - Robert Haralick, acessado em novembro 18, 2025, [https://haralick.org/book\\_chapters/TexturalFeatures.pdf](https://haralick.org/book_chapters/TexturalFeatures.pdf)
  - 15. Bounds for Haralick features in synthetic images with sinusoidal gradients - Frontiers, acessado em novembro 18, 2025, <https://www.frontiersin.org/journals/signal-processing/articles/10.3389/frsip.2023.1271769/full>

16. Documentation error: skimage.feature.graycomatrix, relationship between pixels · Issue #7919 - GitHub, acessado em novembro 18, 2025,  
<https://github.com/scikit-image/scikit-image/issues/7919>
17. skimage.feature — skimage 0.25.2 documentation, acessado em novembro 18, 2025, <https://scikit-image.org/docs/0.25.x/api/skimage.feature.html>
18. How do I mention the direction of neighbours to calculate the glcm in skimage/Python?, acessado em novembro 18, 2025,  
<https://stackoverflow.com/questions/37761411/how-do-i-mention-the-direction-of-neighbours-to-calculate-the-glcm-in-skimage-py>
19. Real time textile defect detection using GLCM in DCT-based compressed images, acessado em novembro 18, 2025, <http://ieeexplore.ieee.org/document/7152203/>
20. Haralick texture features from apparent diffusion coefficient (ADC) MRI images depend on imaging and pre-processing parameters - PMC, acessado em novembro 18, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC5481454/>
21. GLCM Texture: A Tutorial, acessado em novembro 18, 2025,  
<https://ucalgary.scholaris.ca/bitstreams/8f9de234-cc94-401d-b701-f08ceee6cfdf/download>
22. Entropy (information theory) - Wikipedia, acessado em novembro 18, 2025,  
[https://en.wikipedia.org/wiki/Entropy\\_\(information\\_theory\)](https://en.wikipedia.org/wiki/Entropy_(information_theory))
23. acessado em novembro 18, 2025,  
<https://pmc.ncbi.nlm.nih.gov/articles/PMC5017344/#:~:text=The%20function%20value%20of%20Shannon's,derived%20from%20each%20decomposition%20level>
24. Defect Detection in Textures through the Use of Entropy as a Means for Automatically Selecting the Wavelet Decomposition Level - PMC - NIH, acessado em novembro 18, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC5017344/>
25. Computing the local entropy - Hands-On Image Processing with Python [Book] - O'Reilly, acessado em novembro 18, 2025,  
<https://www.oreilly.com/library/view/hands-on-image-processing/9781789343731/74e4d529-39b7-422e-9e70-0b6f9250988e.xhtml>
26. Entropy — skimage 0.25.2 documentation, acessado em novembro 18, 2025,  
[https://scikit-image.org/docs/0.25.x/auto\\_examples/filters/plot\\_entropy.html](https://scikit-image.org/docs/0.25.x/auto_examples/filters/plot_entropy.html)
27. PylImgProc-1: Waterbodies Extraction using Entropy and Otsu's Threshold | by GeoNext, acessado em novembro 18, 2025,  
<https://medium.com/@geonextgis/pyimgproc-1-waterbodies-extraction-using-entropy-and-otsus-threshold-8a9613d2e725>
28. Sobel operator - Wikipedia, acessado em novembro 18, 2025,  
[https://en.wikipedia.org/wiki/Sobel\\_operator](https://en.wikipedia.org/wiki/Sobel_operator)
29. Edge Detection Using OpenCV, acessado em novembro 18, 2025,  
<https://opencv.org/blog/edge-detection-using-opencv/>
30. Edge Detection, acessado em novembro 18, 2025,  
[https://www.cs.auckland.ac.nz/courses/compsci373s1c/PatricesLectures/Edge%20detection-Sobel\\_2up.pdf](https://www.cs.auckland.ac.nz/courses/compsci373s1c/PatricesLectures/Edge%20detection-Sobel_2up.pdf)
31. Sobel Derivatives - OpenCV Documentation, acessado em novembro 18, 2025,  
[https://docs.opencv.org/4.x/d2/d2c/tutorial\\_sobel\\_derivatives.html](https://docs.opencv.org/4.x/d2/d2c/tutorial_sobel_derivatives.html)

32. edge detection - Image Processing - Implementing Sobel Filter - Stack Overflow, acessado em novembro 18, 2025,  
<https://stackoverflow.com/questions/17815687/image-processing-implementing-sobel-filter>
33. Edge Detection in Image Processing: An Introduction - Roboflow Blog, acessado em novembro 18, 2025, <https://blog.roboflow.com/edge-detection/>
34. OpenCV: Detecting Edges, Lines, and Shapes - Packt, acessado em novembro 18, 2025,  
<https://www.packtpub.com/de-eg/learning/how-to-tutorials/opencv-detecting-edges-lines-shapes>
35. Ramer-Douglas-Peucker (RDP) Algorithm in Computer Vision | by Saijyoti Tripathy | Medium, acessado em novembro 18, 2025,  
<https://medium.com/@SaijyotiTripathy/ramer-douglas-peucker-rdp-algorithm-in-computer-vision-15c228f277f0>
36. [opencv] Contour approximation - velog, acessado em novembro 18, 2025,  
<https://velog.io/@dchlseo/opencv-Contour-approximation>
37. OpenCV Contour Approximation - PyImageSearch, acessado em novembro 18, 2025, <https://pyimagesearch.com/2021/10/06/opencv-contour-approximation/>
38. Statistical Asymmetry-based Brain Tumor Segmentation from 3D MR Images, acessado em novembro 18, 2025,  
<https://www.semanticscholar.org/paper/Statistical-Asymmetry-based-Brain-Tumor-from-3D-MR-Yu-Ruppert/3c79f5aaaf3071a151d4bf703daed58390a533708>
39. Brain Tumor Detection and Classification by MRI Using Biologically Inspired Orthogonal Wavelet Transform and Deep Learning Techniques - NIH, acessado em novembro 18, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC8763556/>
40. Automatic Fabric Inspection using GLCM-based Jensen-Shannon Divergence - Informatica, An International Journal of Computing and Informatics, acessado em novembro 18, 2025,  
<https://www.informatica.si/index.php/informatica/article/download/3015/1721>
41. GLCM Texture Features — skimage 0.25.2 documentation, acessado em novembro 18, 2025,  
[https://scikit-image.org/docs/0.25.x/auto\\_examples/features\\_detection/plot\\_glcml.html](https://scikit-image.org/docs/0.25.x/auto_examples/features_detection/plot_glcml.html)
42. Scikit Image - GLCM Texture Features - Tutorials Point, acessado em novembro 18, 2025,  
<https://www.tutorialspoint.com/scikit-image/scikit-image-glcm-texture-features.htm>
43. python - Calculating entropy from GLCM of an image - Stack Overflow, acessado em novembro 18, 2025,  
<https://stackoverflow.com/questions/40919936/calculating-entropy-from-glcm-of-an-image>
44. Contour Features - OpenCV Documentation, acessado em novembro 18, 2025,  
[https://docs.opencv.org/4.x/dd/d49/tutorial\\_py\\_contour\\_features.html](https://docs.opencv.org/4.x/dd/d49/tutorial_py_contour_features.html)

Descriptor	Formulação Matemática	Interpretação Física e Aplicação
<b>Contraste (Inércia)</b>	$\sum_{i,j} (i - j)^2 p(i, j)$	Pondera a probabilidade pelo quadrado da diferença de intensidade. Valores altos indicam transições abruptas (bordas fortes). Em tecidos, picos de contraste local sinalizam defeitos como furos ou nós.
<b>Homogeneidade (IDM)</b>	$\sum_{i,j} \frac{p(i,j)}{1+(i-j)^2}$	Inversamente proporcional ao contraste. O denominador penaliza diferenças de intensidade. É máxima quando a GLCM é diagonal, indicando uniformidade visual. Defeitos estruturais reduzem drasticamente a homogeneidade local.
<b>Energia (ASM)</b>	$\sum_{i,j} p(i, j)^2$	Mede a ordem ou repetitividade. Se a textura é periódica e consistente, a GLCM tem poucas entradas com valores altos, resultando em alta energia (soma dos quadrados). Texturas caóticas distribuem a probabilidade, baixando a energia.
<b>Correlação</b>	$\sum_{i,j} \frac{(i-\mu_i)(j-\mu_j)p(i,j)}{\sigma_i\sigma_j}$	Mede a dependência linear de níveis de cinza. Detecta estruturas direcionais. Em imagens médicas, ajuda a diferenciar tecidos com orientação fibrosa de massas tumorais amorfas.

### 3.1 Fundamentação Estatística

Considere uma imagem digital como uma função discreta de intensidades  $r$  no intervalo  $[0, L - 1]$ . A probabilidade de ocorrência de um nível de intensidade  $r_k$  é dada por:

$$p_r(r_k) = \frac{n_k}{MN}$$

Onde  $n_k$  é o número de pixels com intensidade  $r_k$ , e  $MN$  é o número total de pixels na imagem. A equalização busca uma transformação  $s_k = T(r_k)$  tal que o histograma de saída seja uniforme. Matematicamente, esta transformação é a Função de Distribuição Acumulada (CDF) normalizada da imagem original:

$$s_k = (L - 1) \sum_{j=0}^k p_r(r_j)$$

Esta operação não linear expande o contraste local, revelando detalhes sutis em regiões que estariam ocultas em histogramas concentrados (imagens muito escuras ou muito claras). A aplicação desta técnica é um pré-requisito vital para a detecção de bordas subsequente, pois gradientes de intensidade tornam-se

#### 4.1 Construção e Mecânica da GLCM

A GLCM é uma matriz quadrada  $P(i, j|d, \theta)$  de dimensão  $N_g \times N_g$ , onde  $N_g$  é o número de níveis de cinza. Cada elemento  $(i, j)$  representa a probabilidade conjunta de que dois pixels, separados por uma distância espacial  $d$  e um ângulo  $\theta$ , tenham intensidades  $i$  e  $j$ , respectivamente.

A matriz não normalizada é definida como:

$$P_{\{d,\theta\}}(i,j) = \sum_{x=1}^M \sum_{y=1}^N \begin{cases} 1 & \text{se } I(x,y)=i \text{ e } I(x+\Delta x, y+\Delta y)=j \\ 0 & \text{caso contrário} \end{cases}$$

\$\$

Os parâmetros de deslocamento ( $\Delta x, \Delta y$ ) são derivados de  $d$  e  $\theta$ . Por exemplo, um ângulo de  $0^\circ$  com  $d = 1$  corresponde a  $(\Delta x = 1, \Delta y = 0)$ , analisando a vizinhança horizontal imediata à direita. É crucial notar que, em implementações como a da biblioteca `scikit-image`, a orientação dos ângulos pode seguir o sentido horário, exigindo atenção rigorosa na definição dos vetores de direção.

#### 4.2 Descritores de Haralick: Fórmulas e Interpretação

##### 5.1 Entropia Global vs. Local

A entropia pode ser calculada em duas escalas distintas, com implicações diagnósticas diferentes:

1. **Entropia Global (Baseada em Histograma):** Calculada sobre a distribuição de probabilidade de intensidades de toda a imagem ou ROI (Região de Interesse):

$$H(X) = - \sum_{i=0}^{N_g-1} p(i) \log_2 p(i)$$

Imagens com textura rica ou ruído tendem a ter histogramas planos e, consequentemente, alta entropia. Imagens com grandes áreas de cor sólida têm baixa entropia. Em diagnósticos médicos, a degradação da imagem ou a perda de detalhes texturais pode ser monitorada através da queda nos valores de entropia global.

2. **Entropia Local (Baseada em Elemento Estruturante):** Para segmentação, utiliza-se a entropia local, calculada dentro de uma janela deslizante (geralmente um disco ou quadrado de raio  $r$ ) centrada em cada pixel.

$$E_{local}(x, y) = H(\text{vizinhança}_r(x, y))$$

## 6.1 Convolução e Estimativa de Gradiente

O operador Sobel utiliza dois kernels de convolução  $3 \times 3$ ,  $G_x$  e  $G_y$ , desenhados para detectar variações de intensidade nas direções horizontal e vertical, respectivamente. A estrutura dos kernels incorpora um fator de suavização (pesos gaussianos na linha/coluna central) para reduzir a sensibilidade ao ruído de alta frequência, comum em derivadas puras. ▼

$$\begin{aligned} \$\$ G_x = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix} \quad , \quad G_y = \\ \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ +1 & +2 & +1 \end{bmatrix} \$\$ \end{aligned}$$

A convolução desses kernels com a imagem original  $A$  resulta em dois mapas de derivadas parciais:  $G_x = G_x * A$  e  $G_y = G_y * A$ .

## 6.2 Magnitude e Orientação do Vetor Gradiente

Para cada pixel, o vetor gradiente  $\nabla A$  aponta na direção da maior taxa de variação de intensidade. A magnitude deste gradiente, que corresponde à força da borda, é dada pela norma Euclidiana:

$$G = \sqrt{G_x^2 + G_y^2}$$

## 8. Aplicações Específicas: Detecção de Tumores e Inspeção Têxtil

A teoria apresentada materializa-se em aplicações práticas distintas, conforme evidenciado na literatura de referência.

### 8.1 Análise de Simetria em Imagens Médicas (Tumores Cerebrais)

Em neuroimagem, a detecção de tumores frequentemente explora a simetria bilateral natural do cérebro humano. Tumores introduzem desvios de massa e textura que quebram essa simetria. Algoritmos avançados extraem o Plano Médio Sagital (MSP) e calculam um **Índice de Assimetria (AI)**:

$$AI = \frac{A_{esquerda} - A_{direita}}{A_{total}} \times 100$$

Além da área, compara-se a divergência estatística entre os histogramas e as características GLCM dos hemisférios esquerdo e direito. Um desvio significativo na "Homogeneidade" ou "Entropia" entre regiões homólogas é um biomarcador forte de patologia. ▼