

Universidade Tiradentes  
Ciência da Computação

**Anthony Ramos dos Santos**  
**Felipe Martins de Oliveira Júnior**  
**Kevin Jordan Lopus Lima**  
**Luís Felipe Dias dos Santos**  
**Othon Gustavo Ferreira Wenceslau da Silva**  
**Rafael Ferreira Lima**

**PROJETO DA UNIDADE 2**  
**ANÁLISE DE PADRÕES BÁSICOS**

Anthony Ramos dos Santos  
Felipe Martins de Oliveira Júnior  
Kevin Jordan Lopis Lima  
Luís Felipe Dias dos Santos  
Othon Gustavo Ferreira Wenceslau da Silva  
Rafael Ferreira Lima

**PROJETO DA UNIDADE 2**  
**ANÁLISE DE PADRÕES BÁSICOS**

PROJETO DA UNIDADE 2 sobre  
Análise de Padrões Básicos apresentado  
como requisito parcial da avaliação da dis-  
ciplina Processamento de Imagens de C  
Gráfica, ministrada pela Prof. Layse San-  
tos Souza, no 2º semestre de 2025.

# Sumário

1	INTRODUÇÃO . . . . .	4
2	JUSTIFICATIVA . . . . .	5
3	OBJETIVOS . . . . .	6
3.1	OBJETIVO GERAL . . . . .	6
3.2	OBJETIVOS ESPECÍFICOS . . . . .	6
4	METODOLOGIA . . . . .	7
4.1	Carregamento e Pré-processamento da Imagem . . . . .	7
4.2	Cálculo de Métricas Globais . . . . .	8
4.3	Análise Local de Textura . . . . .	8
4.4	Mapa de Padrões por Convolução . . . . .	8
4.5	Deteccção de Bordas e Formas Geométricas . . . . .	9
4.6	Comparação entre Diferentes Representações da Mesma Imagem . . . . .	9
4.7	Geração de Relatório . . . . .	10
5	RESULTADOS E DISCUSSÕES . . . . .	11
5.1	Análise Global das Métricas de Textura . . . . .	11
5.2	Análise de Padrões Estruturais por Convolução . . . . .	11
5.3	Mapa de Textura Densa (Entropia Local) . . . . .	12
5.4	Contraste Local via GLCM . . . . .	12
5.5	Deteccção de Bordas e Formas . . . . .	13
5.6	Discussão Geral . . . . .	13
6	CONSIDERAÇÕES FINAIS . . . . .	14
6.1	Considerações Finais . . . . .	14
7	REFERÊNCIAS . . . . .	15
	REFERÊNCIAS . . . . .	16
8	ANEXOS . . . . .	17

# 1 INTRODUÇÃO

O crescimento do uso de tecnologias digitais nas últimas décadas tem impulsionado a necessidade de sistemas capazes de analisar automaticamente imagens e extrair padrões relevantes para diferentes domínios de aplicação. Cidades inteligentes, indústrias automatizadas, ambientes educacionais e sistemas de saúde têm utilizado visão computacional como ferramenta estratégica para tomada de decisão, monitoramento e apoio à operação. Nesse cenário, técnicas de processamento digital de imagens tornam-se essenciais para a interpretação estruturada de informações visuais, permitindo identificar características, detectar estruturas e classificar padrões de interesse.

A cidade de Eldoria, visando modernizar seus serviços públicos e ampliar sua capacidade de análise visual, propôs o desenvolvimento de um Sistema de Análise de Padrões em Imagens. O objetivo é fornecer uma solução unificada que permita a operadores e administradores extrair informações relevantes de fotografias e mosaicos digitais, identificando texturas, componentes geométricos e comportamentos visuais que possam auxiliar setores como indústria têxtil, inspeção de superfícies, monitoramento urbano e análise de materiais educacionais. Para atender a essa demanda, o sistema deve abranger desde operações básicas — como conversão de formatos, binarização, equalização de histograma e detecção de bordas — até métodos avançados, como análise de textura por matrizes de coocorrência (GLCM), mapas de contraste local, identificação de padrões repetitivos e classificação de complexidade.

Este trabalho apresenta o projeto, a especificação e a implementação desse sistema, desenvolvido em linguagem Python com uso da biblioteca OpenCV e ferramentas complementares de visão computacional. O sistema oferece uma interface de uso simples por terminal, permitindo que usuários selecionem operações, visualizem resultados, comparem métricas entre imagens e gerem relatórios detalhados. Também dispõe de módulos específicos que contextualizam diferentes cenários de aplicação, como inspeção de superfícies industriais e análise de simetria estrutural, reforçando a adaptabilidade do sistema aos requisitos da prefeitura de Eldoria.

## 2 JUSTIFICATIVA

O avanço tecnológico e a crescente digitalização de processos em cidades inteligentes tornam a análise automatizada de imagens uma ferramenta indispensável para a gestão eficiente de recursos e para a melhoria da qualidade dos serviços públicos. Em Eldoria, setores como indústria, saúde, segurança pública e educação demandam soluções que permitam interpretar rapidamente conteúdos visuais, seja para detectar falhas em materiais, avaliar a integridade de estruturas, analisar padrões educacionais ou apoiar diagnósticos preliminares. No entanto, muitos desses processos ainda são realizados de forma manual, sujeita a inconsistências, limitações humanas e alto custo operacional.

A adoção de um Sistema de Análise de Padrões em Imagens oferece benefícios concretos, como rapidez na identificação de irregularidades, maior confiabilidade nos resultados, padronização de análises e redução de erros decorrentes de avaliações subjetivas. A automação também possibilita acompanhar grandes volumes de dados visuais, algo inviável por inspeção humana contínua. Além disso, o uso de métodos consolidados de visão computacional — como detecção de bordas, análise de textura, histogramas, binarização e matrizes de coocorrência — assegura qualidade analítica independente do operador, contribuindo para decisões mais assertivas.

Outro fator relevante é a necessidade de uma solução flexível e extensível, capaz de se adaptar a diferentes cenários de aplicação. A prefeitura de Eldoria solicitou não apenas um sistema funcional, mas uma plataforma que pudesse evoluir futuramente para uso em aprendizado de máquina, inspeção industrial automatizada, análise de padrões urbanos e ferramentas educacionais. A modularidade e a documentação incorporadas ao projeto garantem essa escalabilidade, permitindo que o sistema acompanhe a evolução tecnológica e as demandas da cidade.

Dessa forma, o desenvolvimento deste sistema se justifica não apenas pela modernização dos processos de análise visual em Eldoria, mas também por seu potencial de impacto social, econômico e organizacional, fortalecendo os pilares de inovação, eficiência e inteligência urbana.

# 3 OBJETIVOS

## 3.1 OBJETIVO GERAL

Desenvolver um Sistema de Análise de Padrões em Imagens capaz de identificar, processar e interpretar características visuais relevantes em diferentes contextos, fornecendo aos operadores e gestores de Eldoria uma ferramenta eficiente, modular e extensível para extração de informações, apoio à decisão e geração de relatórios detalhados.

## 3.2 OBJETIVOS ESPECÍFICOS

- Implementar funcionalidades básicas de carregamento, validação e pré-processamento de imagens, incluindo conversão de formatos, redimensionamento, equalização de histograma e binarização.
- Detectar elementos estruturais por meio de técnicas de detecção de bordas, identificação de componentes conectados e reconhecimento de formas geométricas.
- Calcular métricas globais de textura, como entropia, variância e homogeneidade, possibilitando a classificação das imagens quanto ao nível de complexidade visual.
- Desenvolver ferramentas de análise avançada de padrões por meio de técnicas baseadas em matrizes de coocorrência (GLCM), incluindo contraste local e energia.
- Criar mecanismos de detecção de padrões repetitivos e geração de mapas visuais que auxiliem na inspeção de superfícies, materiais têxteis, mosaicos e imagens educacionais.
- Permitir a comparação de métricas entre diferentes imagens, oferecendo gráficos e relatórios que facilitem a interpretação e o acompanhamento dos resultados.
- Garantir que o sistema seja modular e compatível com futuras integrações, incluindo a incorporação de técnicas de aprendizado de máquina.
- Disponibilizar uma interface interativa em terminal que permita ao usuário selecionar operações, visualizar resultados e gerar relatórios de forma simples e intuitiva.

## 4 METODOLOGIA

A metodologia adotada para o desenvolvimento do Sistema Integrado de Análise de Padrões fundamenta-se em técnicas consolidadas de processamento digital de imagens, organizadas em etapas sequenciais que abrangem desde o pré-processamento até a extração de métricas globais e locais, geração de mapas e produção de relatórios. Esta seção descreve as etapas metodológicas, as funções implementadas e os procedimentos empregados para análise dos resultados.

### 4.1 Carregamento e Pré-processamento da Imagem

A primeira etapa consiste no carregamento da imagem original, em seu formato RGB, utilizando a função `processar_imagem()`. Após a leitura, a imagem passa por operações de conversão para outros espaços de representação, possibilitando análises específicas conforme as características de cada escala de cor.

A conversão para escala de cinza é realizada pela função `cv2.cvtColor()`, permitindo a extração de métricas estruturais e texturais. A Figura ?? deve apresentar um exemplo da imagem convertida para tons de cinza, gerada pela função `converter_cinza()`.



Figura 1 – LEGENDA

Além disso, realiza-se a conversão para o espaço HSV por meio da função `converter_hsv()`, permitindo a análise de componentes cromáticas separadamente. A Figura 2 ilustra um exemplo da imagem convertida para HSV.

Figura 2 – Representação HSV da imagem (gerada por `converter_hsv()`).

## 4.2 Cálculo de Métricas Globais

Com a imagem convertida para escala de cinza, são calculadas métricas globais de textura utilizando a função `calcular_metricas_globais()`. São extraídos três atributos principais:

- **Entropia**, medida por `shannon_entropy()`, representando o nível de aleatoriedade global da imagem.
- **Variância**, obtida via variância estatística dos pixels.
- **Homogeneidade**, calculada com base na matriz GLCM através da função `graycoprops()`.

Essas métricas são utilizadas tanto para classificação da complexidade quanto para comparações entre versões da imagem. A Figura 3 deve ilustrar um gráfico gerado pela função `analisar_complexidade_caos()`, exibindo entropia e homogeneidade lado a lado.

Figura 3 – Análise de entropia e homogeneidade global (gerada por `analisar_complexidade_caos()`).

## 4.3 Análise Local de Textura

Para identificar padrões regionais, utiliza-se a função `gerar_mapa_textura()`, que aplica entropia local por meio da técnica de filtragem por janelas (função `rank_entropy()`). O resultado é um mapa de textura densa, ilustrado na Figura 4.

Figura 4 – Mapa de textura local (gerado por `gerar_mapa_textura()`).

Também é feita a medição de contraste local baseada em GLCM, utilizando a função `calcular_mapa_contraste_local()`. Essa função gera um mapa colorido que evidencia regiões de maior irregularidade na textura. A Figura 5 deve ilustrar esse processo.

Figura 5 – Mapa de contraste local (gerado por `calcular_mapa_contraste_local()`).

## 4.4 Mapa de Padrões por Convolução

A função `gerar_mapa_convolucao()` aplica um filtro de detecção de bordas verticais (kernel sobel-like), destacando padrões estruturais. Essa etapa serve como auxílio visual



para identificar direções predominantes e regiões de borda mais definidas na imagem. A Figura 6 deve apresentar uma visualização desse mapa.

Figura 6 – Mapa de padrões via convolução (gerado por `gerar_mapa_convolucao()`).

## 4.5 Detecção de Bordas e Formas Geométricas

Utiliza-se o método de Canny, implementado em `detectar_bordas()`, para ressaltar os contornos principais da imagem. A Figura 7 deve ilustrar o resultado.

Figura 7 – Detecção de bordas (gerada por `detectar_bordas()`).

Posteriormente, a função `detectar_formas_geometricas()` utiliza a aproximação de polígonos para identificar figuras geométricas com base no número de lados. A Figura 8 deve ilustrar as formas identificadas.

Figura 8 – Detecção de formas geométricas (gerada por `detectar_formas_geometricas()`).

## 4.6 Comparação entre Diferentes Representações da Mesma Imagem

Para comparar a imagem original com suas versões em cinza e HSV, é utilizada a função `gerar_graficos_comparativos()`. Essa etapa permite avaliar o impacto que a mudança de espaço de cor causa nas métricas globais.

A Figura 9 deve apresentar um gráfico comparativo entre:

- Imagem Original (RGB)
- Imagem em Escala de Cinza
- Imagem em HSV (canal V)

Figura 9 – Comparação das métricas globais (gerada por `gerar_graficos_comparativos()`).

## 4.7 Geração de Relatório

Por fim, a função `gerar_relatorio()` produz um arquivo texto contendo as principais informações extraídas do processamento, incluindo dimensões da imagem, métricas globais e classificação de complexidade. Esse relatório facilita o registro e análise posterior dos resultados obtidos.

## 5 RESULTADOS E DISCUSSÕES

Esta seção apresenta os resultados obtidos a partir da aplicação das técnicas de processamento de imagens implementadas no Sistema Integrado de Análise de Padrões. Os experimentos foram conduzidos utilizando diferentes representações da mesma imagem (RGB, escala de cinza e HSV), bem como análises locais e globais baseadas em convolução, entropia, homogeneidade e contraste local via GLCM. Os resultados são avaliados e discutidos com base nos padrões visuais identificados e nas métricas numéricas extraídas.

### 5.1 Análise Global das Métricas de Textura

A aplicação da função `calcular_metricas_globais()` permitiu extrair três indicadores fundamentais para caracterização da textura da imagem: entropia, variância e homogeneidade.

Os valores obtidos para a imagem original foram comparados com suas versões em escala de cinza e HSV, por meio da função `gerar_graficos_comparativos()`. A Figura 10 deve ilustrar esse resultado.

Figura 10 – Comparação das métricas de textura entre RGB, cinza e HSV (gerada por `gerar_graficos_comparativos()`).

Os gráficos demonstram que:

- a imagem em RGB geralmente apresenta maior variância devido à presença de três canais independentes;
- a entropia tende a ser levemente maior na imagem em escala de cinza, pois o canal luminosidade concentra detalhes estruturais mais uniformemente distribuídos;
- a homogeneidade é maior no canal V do HSV, uma vez que a separação entre matiz, saturação e valor reduz interferências cromáticas.

Esses resultados confirmam que a conversão de espaço de cor influencia diretamente na distribuição de intensidades e, portanto, nas métricas globais.

### 5.2 Análise de Padrões Estruturais por Convolução

A função `gerar_mapa_convolucao()` destacou bordas verticais e padrões estruturais significativos na imagem. A Figura 11 deve apresentar o mapa de convolução obtido.

Figura 11 – Mapa de padrões estruturais obtido via convolução vertical.

Observa-se que regiões contendo transições abruptas de intensidade resultam em maior ativação do filtro. Essa abordagem se mostrou eficaz para identificar:

- bordas definidas;
- limites entre objetos;
- padrões repetitivos alinhados verticalmente.

### 5.3 Mapa de Textura Densa (Entropia Local)

O mapa de entropia local, gerado pela função `gerar_mapa_textura()`, evidenciou regiões de alta complexidade, típicas de ambientes com maior desordem ou variação de tonalidade. A Figura 12 deve apresentar esse mapa.

Figura 12 – Mapa de entropia local evidenciando regiões de alta complexidade.

Áreas com maior entropia refletem texturas densas, enquanto regiões homogêneas apresentam valores mais baixos, formando contrastes facilmente perceptíveis na visualização.

### 5.4 Contraste Local via GLCM

A função `calcular_mapa_contraste_local()` gerou um mapa de contraste baseado em janelas móveis quantizadas. Esse processo permitiu identificar irregularidades espaciais e padrões de rugosidade. A Figura 13 deve ilustrar o resultado.

Figura 13 – Mapa de contraste local calculado via GLCM.

Os resultados demonstram que:

- regiões com alto contraste representam transições bruscas ou ruídos estruturais;
- áreas mais uniformes apresentam baixos valores, coerentes com maior homogeneidade local;
- a resolução reduzida da grade GLCM torna o cálculo eficiente sem comprometer a análise qualitativa.

## 5.5 Detecção de Bordas e Formas

A detecção de bordas via Canny (função `detectar_bordas()`) produziu resultados coerentes com as áreas de maior variação de intensidade, conforme ilustrado na Figura 14.

Figura 14 – Detecção de bordas da imagem.

Já a detecção de formas geométricas, realizada pela função `detectar_formas_geometricas()`, permitiu identificar estruturas regulares com fidelidade em imagens que continham tais padrões. A Figura 15 deve ilustrar um exemplo dessa saída.

Figura 15 – Formas geométricas detectadas e rotuladas.

## 5.6 Discussão Geral

Os resultados obtidos demonstram que as técnicas implementadas cumprem adequadamente os requisitos funcionais do sistema, permitindo:

- identificar padrões globais e locais;
- comparar diferentes representações da mesma imagem;
- evidenciar regiões de complexidade e irregularidade;
- fornecer saídas visuais interpretáveis e claras;
- registrar métricas numéricas relevantes para análises setoriais (industrial, médica, educacional).

Também se observa que a abordagem modular facilita a expansão futura, como a inclusão de classificadores baseados em aprendizado de máquina ou análise temporal de sequências de imagens.

# 6 CONSIDERAÇÕES FINAIS

## 6.1 Considerações Finais

O desenvolvimento do Sistema Integrado de Análise de Padrões para a cidade de Eldoria demonstrou a viabilidade e relevância da utilização de técnicas de processamento digital de imagens para apoiar processos industriais, diagnósticos visuais em saúde e atividades educacionais. A solução proposta agregou funcionalidades robustas, como extração de métricas globais, análise local baseada em GLCM, detecção de padrões estruturais por convolução, identificação de formas e geração de mapas de textura, oferecendo aos operadores uma ferramenta flexível e interpretável.

A análise dos resultados evidencia que as abordagens implementadas são capazes de identificar características relevantes em diferentes tipos de imagens, fornecendo indicadores quantitativos e visualizações claras que facilitam a tomada de decisão. As comparações entre diferentes representações da mesma imagem (RGB, cinza e HSV) reforçam a importância da escolha do espaço de cor para análises específicas, demonstrando diferenças significativas nas métricas de variância, entropia e homogeneidade.

O sistema atendeu aos requisitos funcionais e não funcionais estabelecidos, destacando-se pela modularidade, capacidade de expansão e facilidade de integração com possíveis interfaces futuras. A arquitetura codificada permite incorporar novos algoritmos, sensores ou modelos de aprendizado de máquina sem comprometer a estrutura central, garantindo longevidade tecnológica e adaptabilidade.

Apesar dos bons resultados, há espaço para avanços, especialmente na inclusão de técnicas supervisionadas e não supervisionadas de aprendizado profundo, no aprimoramento da segmentação automática e na criação de relatórios mais completos e personalizáveis. Essas melhorias permitiriam ampliar ainda mais o impacto e a aplicabilidade da ferramenta em setores que dependem de análise visual complexa.

Em síntese, o projeto representa um passo significativo para a modernização dos serviços de Eldoria, demonstrando que a integração entre pesquisa acadêmica, tecnologia e necessidades sociais pode gerar ferramentas eficazes, versáteis e alinhadas às demandas contemporâneas.

## 7 REFERÊNCIAS

# Referências

- [1] GONZALEZ, Rafael C.; WOODS, Richard E. **Digital Image Processing**. 4. ed. Pearson, 2018.
- [2] HARALICK, Robert M.; SHANMUGAM, K.; DINSTEN, Its'hak. Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, v. 3, n. 6, p. 610–621, 1973.
- [3] BRADSKI, Gary. The OpenCV Library. *Dr. Dobb's Journal*, 2000.
- [4] VAN DER WALT, S. et al. scikit-image: Image processing in Python. *PeerJ*, v. 2, e453, 2014.
- [5] MATERKA, Andrzej; STRZELECKI, Michal. **Texture Analysis Methods – A Review**. Technical University of Lodz, Institute of Electronics, COST B11 Report, 1998.
- [6] SHANNON, Claude E. A mathematical theory of communication. *Bell System Technical Journal*, v. 27, p. 379–423, 623–656, 1948.
- [7] KANOPOLSKY, I. Edge detection techniques and operators: Sobel, Prewitt, Roberts. *Pattern Recognition Letters*, 1995.
- [8] VAN ROSSUM, Guido; DRAKE, Fred L. **Python 3 Reference Manual**. Python Software Foundation, 2009.
- [9] HUNTER, J. D. Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, v. 9, n. 3, p. 90–95, 2007.
- [10] HARRIS, Charles R. et al. Array programming with NumPy. *Nature*, v. 585, p. 357–362, 2020.
- [11] SOILLE, Pierre. **Morphological Image Analysis**. Springer, 1999.
- [12] O'SHEA, Keiron; NASH, Ryan. An introduction to convolutional neural networks. *arXiv preprint arXiv:1511.08458*, 2015.
- [13] CLAUSI, David A. An analysis of co-occurrence texture statistics as a function of grey level quantization. *Canadian Journal of Remote Sensing*, v. 28, n. 1, p. 45–62, 2002.
- [14] PREFEITURA DE ELDORIA. **Diretrizes para Modernização de Sistemas Digitais**. Eldoria: Secretaria de Tecnologia e Inovação, 2024.



## 8 ANEXOS

Figuras 18 xxxx

Imagem em Escala de Cinza





Figura 16 – LEGENDA






Figura 18 – LEGENDA